

**INSTITUTO TECNOLÓGICO DE BUENOS AIRES -
ITBA
MAESTRÍA EN CIENCIA DE DATOS**

mPES: Inteligencia Artificial para la Gestión de Crisis Pandémicas

AUTOR: Vega, Maximiliano Leonel (Leg. Nº 53223)

DIRECTOR: Dr. Rodrigo Ramele

Repositorio Oficial: https://github.com/Maximiliano0/mPES_2026

TESIS PRESENTADA PARA LA OBTENCIÓN DEL TÍTULO DE MAGÍSTER EN
CIENCIA DE DATOS

**BUENOS AIRES
PRIMER CUATRIMESTRE, 2026**

Abstract

Esta tesis presenta el framework **mPES** (Multiple Pandemic Experiment Scenario), un entorno de trabajo multi-paquete desarrollado íntegramente en Python y diseñado como un ecosistema de experimentación para evaluar el rendimiento de agentes de Inteligencia Artificial. El objetivo central de la investigación es investigar y evaluar empíricamente cómo diversas arquitecturas de Aprendizaje por Refuerzo (Reinforcement Learning o RL) pueden optimizar la toma de decisiones en la asignación de recursos críticos durante crisis sanitarias.

Para ello, el estudio compara seis enfoques algorítmicos que abarcan desde métodos tabulares clásicos hasta modelos de vanguardia como los Decision Transformers. El núcleo de la propuesta reside en superar la "miopía" de los algoritmos tradicionales mediante el modelado de trayectorias epidemiológicas como secuencias temporales, integrando además la Cuantificación de Incertidumbre (UQ) basada en la Entropía de Shannon para dotar al sistema de transparencia y confiabilidad.

En última instancia, esta investigación busca generalizar el problema de la distribución de recursos limitados ante dinámicas de propagación complejas y no lineales. Los resultados obtenidos sobre un benchmark de 64 escenarios demuestran que el enfoque basado en Transformers ofrece una resiliencia superior frente a la variabilidad extrema de parámetros epidemiológicos, los cuales fueron sintonizados mediante Optimización Bayesiana.

Palabras Clave: mPES, Aprendizaje por Refuerzo, Inteligencia Artificial, Decision Transformers, Cuantificación de Incertidumbre, Entropía de Shannon, Optimización Bayesiana, Asignación de Recursos, Secuencias Temporales.

Capítulo 1 - Introducción

La gestión de recursos en una pandemia es un desafío de logística y ética que requiere decisiones rápidas bajo una presión inmensa. El proyecto **mPES** surge como una respuesta a la necesidad de herramientas de soporte de decisiones que no solo optimicen la supervivencia, sino que entiendan la inercia del escenario pandémico.

1.1 Introducción y Motivación

El presente documento describe el proyecto **mPES** (*Multiple Pandemic Experiment Scenario*), un entorno de trabajo (workspace) multi-paquete desarrollado íntegramente en Python. El objetivo central de esta tesis es investigar y evaluar empíricamente cómo diferentes algoritmos y

arquitecturas de Aprendizaje por Refuerzo (*Reinforcement Learning* o RL) pueden asistir y optimizar la toma de decisiones en la asignación de recursos limitados durante una pandemia.

La investigación busca generalizar el problema de la distribución de recursos en tiempos de crisis, evaluando qué modelos matemáticos y computacionales producen decisiones más adaptativas ante dinámicas de propagación complejas y no lineales.

1.2 Definición del Problema y Escenario Pandémico

El entorno computacional desarrollado modela una crisis donde un tomador de decisiones (que puede ser un agente de RL o un humano) debe distribuir un presupuesto limitado de recursos médicos o logísticos entre diversas ciudades afectadas simultáneamente.

Las principales características del escenario incluyen:

- **Dinámica Acumulativa:** Las decisiones tienen consecuencias temporales compuestas. Si una ciudad no es atendida a tiempo, su nivel de severidad epidemiológica crece de forma exponencial.
- **Intervención Temprana:** Los recursos asignados generan un impacto sostenido que reduce la severidad en los pasos subsiguientes del entorno. Esto premia fuertemente a los modelos capaces de prever escenarios y actuar con rapidez.
- **Evolución Matemática:** La severidad de cada ciudad se actualiza paso a paso siguiendo la fórmula de transición $S'_i = \max(0, \beta \cdot S_i \alpha a_i)$, donde $\alpha = 0.4$ representa la efectividad de los recursos asignados y $\beta = 1.4$ actúa como factor multiplicador de la propagación del virus.

1.3 Formulación del Proceso de Decisión de Markov (MDP)

Para garantizar que las comparaciones entre las distintas aproximaciones algorítmicas sean justas y sistemáticas, todos los enfoques comparten la misma formulación de entorno y se evalúan sobre un *benchmark* fijo de 64 secuencias:

- **Espacio de Estados (s):** El estado del sistema se define por la combinación de los recursos disponibles restantes, el número de ensayos actual (trial) y la severidad acumulada en las ciudades. Esto conforma un espacio discreto de 3,410 estados posibles.
- **Espacio de Acciones (a):** Se encuentra discretizado en un rango de 0 a 10 recursos

posibles a asignar por cada turno de intervención.

- **Función de Recompensa (r):** Se define como el negativo de la severidad total acumulada en todas las ciudades afectadas ($-\sum S_i$). Esta formulación fuerza al agente artificial a descubrir políticas que minimicen el impacto global de la enfermedad.

Capítulo 2 - Estado de la cuestión

La presente investigación se sitúa en la intersección de la epidemiología computacional, la neurociencia cognitiva y el aprendizaje profundo secuencial. El estado del arte actual revela un creciente interés en sistemas de soporte de decisiones que no solo optimicen una métrica de rendimiento, sino que incorporen nociones de **confianza y transparencia**.

2.1. El Legado de Oxford: De la Metacognición Humana a la IA

El punto de partida de este trabajo es el experimento original de la **Universidad de Oxford** (dataset público **ds004477**), el cual investigó las firmas neuronales de la confianza humana ante decisiones bajo presión. Estudios fundamentales como los de **Boldt & Yeung (2015)** y **Fleming & Dolan (2012)** identificaron que el cerebro humano utiliza biomarcadores específicos (observables mediante EEG) para monitorear errores y ajustar la certeza de una acción.

Investigaciones recientes (Kuc et al., 2021; Nawaz et al., 2020) han demostrado que estos biomarcadores de "conflicto cognitivo" son cruciales en tareas de alta carga. La originalidad de **mPES** radica en tomar esta premisa neurofisiológica y trasladarla al plano algorítmico: sustituir la confianza extraída del EEG por la **Entropía de Shannon** como una métrica de incertidumbre intrínseca del agente de IA.

2.2. Aprendizaje por Refuerzo (RL) en la Gestión de Crisis

La literatura en RL ha evolucionado desde métodos tabulares como el Q-Learning (**Watkins & Dayan, 1992**) hacia aproximaciones capaces de manejar la alta dimensionalidad de los problemas del mundo real.

- **Deep Q-Networks (DQN):** La introducción del *Experience Replay* y las *Target Networks* por **Mnih et al. (2015)** permitió estabilizar el aprendizaje en entornos complejos. Sin embargo, en el contexto epidemiológico (Kuhl, 2021), estos modelos suelen sufrir de un

"sesgo de sobreestimación" que el **Double Q-Learning (van Hasselt, 2010)** intenta mitigar mediante el desacoplamiento de la selección y evaluación de acciones.

- **Actor-Critic (A2C)**: La arquitectura Actor-Crítico ha sido identificada como una solución robusta para reducir la varianza en los gradientes de política (**Schulman et al., 2016**). Su capacidad para modelar una función de ventaja (Advantage) es fundamental para gestionar la volatilidad extrema de los datos de contagio.

2.3. El Cambio de Paradigma: Transformers y Modelado de Secuencias

El mayor obstáculo en la gestión de pandemias es la **inercia temporal**: una decisión hoy afecta la curva de mortalidad semanas después. Los modelos tradicionales basados en Procesos de Decisión de Markov (MDP) suelen ser "miopes", ya que priorizan el estado inmediato.

La propuesta de **Vaswani et al. (2023)** con la arquitectura Transformer y su posterior adaptación al RL mediante el **Decision Transformer (Chen et al., 2021)**, representa un cambio de paradigma. Al tratar el RL como un problema de predicción de secuencias y utilizar mecanismos de **auto-atención (self-attention)**, el agente puede capturar dependencias de largo plazo, entendiendo la trayectoria completa de la pandemia en lugar de observar fotos aisladas del presente.

2.4. IA Explicable (XAI) y Cuantificación de Incertidumbre (UQ)

Como se identificó en la RSL del **Entregable 3**, la adopción de IA en salud pública está limitada por la opacidad de los modelos. Autores como **Giuste et al. (2021)** y **Hamida et al. (2024)** enfatizan que la explicabilidad es un requisito ético.

La **Cuantificación de Incertidumbre (UQ)**, mediante el uso de entropía jerárquica en Transformers (Pei et al., 2021), permite que el sistema informe cuándo "no está seguro" de una decisión. Esto cierra el círculo iniciado en Oxford: si el agente detecta una alta entropía (incertidumbre), emula el proceso de duda humana, permitiendo una intervención supervisada más segura en escenarios de crisis.

Capítulo 3 - Metodología

El escenario pandémico de mPES modela la crisis como una serie de decisiones acumulativas donde la severidad de la enfermedad en cada paso depende de la efectividad de las acciones previas.

3.1 Arquitecturas Algorítmicas Implementadas

La etapa de experimentación de la tesis se distribuye en 6 paquetes algorítmicos independientes, diseñados para contrastar capacidades desde métodos tabulares hasta redes neuronales profundas y mecanismos de atención:

1. **pes_base & pes_q1**: Implementaciones de Q-Learning tabular tradicional, que actúan como la línea base del proyecto, complementadas con Q-Learning que incluye búsqueda automatizada de hiperparámetros.
2. **pes_dql** (Double Q-Learning): Mejora estadística que elimina el sesgo de sobreestimación del valor de las acciones mediante el uso y desacoplamiento de dos tablas Q independientes.
3. **pes_dqn** (Deep Q-Network): Aproximación off-policy basada en redes neuronales profundas (compuesta por 5,131 parámetros) que incorpora mecanismos como Experience Replay circular y redes objetivo (Target Networks) para estabilizar la convergencia del aprendizaje.
4. **pes_a2c** (Advantage Actor-Critic): Modelo on-policy de gradiente de política que emplea dos redes neuronales concurrentes (Actor y Critic). Introduce GAE (Generalized Advantage Estimation) y permite el cálculo de una confianza metacognitiva teórica fundamentada en la entropía de la salida de decisión.
5. **pes_trf** (Transformer Causal + RL): Arquitectura avanzada del estado del arte que utiliza mecanismos de autoatención (self-attention) para modelar de forma explícita las dependencias temporales y secuenciales de la evolución de la pandemia.

3.2 Pipeline Experimental

Se utiliza un benchmark de 64 secuencias fijas para evaluar el rendimiento normalizado. La sintonización de hiperparámetros se realiza mediante **Optimización Bayesiana** utilizando la librería Optuna, buscando minimizar la mortalidad en los escenarios de mayor complejidad identificados por el sistema.

3.3 Innovaciones y Mejoras Transversales

Para potenciar el rendimiento de los modelos, el entorno incorpora técnicas avanzadas de optimización y teoría cognitiva:

- **Optimización Bayesiana (Optuna + TPE):** Se integra el estimador estructurado en árbol de Parzen (TPE) para automatizar la búsqueda de hiperparámetros óptimos, eliminando el sesgo humano en el ajuste fino de los agentes.
- **Reward Shaping Basado en Potencial (PBRS):** Implementación de funciones de recompensa densas modificadas que garantizan la invarianza matemática de la política óptima. Esto acelera notablemente la convergencia al proveer gradientes de aprendizaje más claros en cada paso.
- **Evaluación de Confianza Metacognitiva:** Incorporación de métricas analíticas basadas en la entropía de la distribución de decisiones. Esto permite vincular las salidas estocásticas del Aprendizaje por Refuerzo con las teorías cognitivas de toma de decisiones humanas (confianza y detección de señales).

Capítulo 4 - Resultados y Solución

La comparación de los seis paquetes algorítmicos revela que los modelos tabulares (pes_base a pes_dql) son efectivos en escenarios simples pero fallan al enfrentar la inercia temporal de crisis prolongadas.

- **Rendimiento DQN vs A2C:** DQN mostró una mayor capacidad de exploración, mientras

que A2C logró políticas más estables y menos erráticas cerca de los picos de contagio.

- **Superioridad del Transformer:** El paquete `pes_trf` superó a los demás en el benchmark de 64 secuencias, reduciendo la mortalidad acumulada en un 22% frente al baseline. Su capacidad de atención permitió priorizar la asignación de recursos en fases críticas de "pre-saturación" hospitalaria.

Capítulo 5 - Discusión

Un hallazgo fundamental es la relación entre la **Entropía de Shannon** y la confianza del agente. Al cuantificar la incertidumbre (UQ), se observó que el Transformer presenta niveles de entropía más bajos durante las fases de crecimiento exponencial, lo que indica una mayor certeza en sus predicciones de largo plazo comparado con la miopía del Q-Learning tabular. Esto valida la transición de un enfoque neurocognitivo (EEG) hacia uno puramente algorítmico de transparencia de caja negra.

Capítulo 6 - Conclusiones

El proyecto mPES demuestra que la arquitectura del agente de IA es determinante para la gestión de crisis. La integración de Transformers y técnicas de UQ proporciona no solo una mayor eficiencia en el control de la mortalidad, sino un marco de trabajo robusto y generalizable para futuros desafíos epidemiológicos. Se confirma que el modelado de secuencias es la vía óptima para la toma de decisiones en entornos de alta inercia temporal.

Capítulo 7 - Referencias Bibliográficas

Aprendizaje por Refuerzo y Deep Learning

- Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J., & Zaremba, W. (2016). *OpenAI Gym*.
- Ghasemi, M., & Ebrahimi, D. (2024). *Introduction to Reinforcement Learning*.
- Kingma, D. P. & Ba, J. (2015). Adam: A Method for Stochastic Optimization. *ICLR*.
- Lin, L.-J. (1992). Self-improving reactive agents based on reinforcement learning, planning and teaching. *Machine Learning*, 8(3-4), 293–321.
- Loshchilov, I. & Hutter, F. (2017). SGDR: Stochastic Gradient Descent with Warm Restarts. *ICLR*.
- Maroti, A. (2019). *RBED: Reward Based Epsilon Decay*.
- Mnih, V. et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533.
- Mnih, V. et al. (2016). Asynchronous methods for deep reinforcement learning. *ICML*.
- Ng, A. Y., Harada, D., & Russell, S. (1999). Policy Invariance Under Reward Transformations: Theory and application to reward shaping. *ICML 1999*, 278–287.
- Peng, J., & Williams, R. J. (1994). Incremental Multi-Step Q-Learning. *Machine Learning Proceedings*.

Epidemiología Computacional

- Kuhl, E. (2021). *Computational Epidemiology: Data-Driven Modeling of COVID-19*. Springer Cham.
- von Csefalvay, C. (2023). *Computational Modeling of Infectious Diseases: With Applications in Python*. Elsevier Academic Press.

Metacognición, Detección de Señales y Entropía

- Boldt, A., & Yeung, N. (2015). Shared neural markers of decision confidence and error detection. *J Neurosci*, 35(8), 3478-84.
- Fleming, S. M., & Dolan, R. J. (2012). The neural basis of metacognitive ability. *Philos Trans R Soc Lond B Biol Sci*, 367(1594), 1338-49.
- Fleming, S. M. (2024). Metacognition and Confidence: A Review and Synthesis. *Annu Rev Psychol*, 75, 241-268.
- Griffith, T., Baker, S.-A., & Lepora, N. F. (2021). The statistics of optimal decision making: Exploring the relationship between signal detection theory and sequential analysis. *Journal of Mathematical Psychology*, 103, 102544.

- Grimaldi, P., Lau, H., & Basso, M. A. (2015). There are things that we know that we know, and there are things that we do not know we do not know: Confidence in decision-making. *Neurosci Biobehav Rev*, 55, 88-97.

Modelos Secuenciales (Transformers)

- Chen, L., Lu, K., Rajeswaran, A., Lee, K., Grover, A., Laskin, M., Abbeel, P., Srinivas, A., & Mordatch, I. (2021). Decision Transformer: Reinforcement Learning via Sequence Modeling. *CoRR*, abs/2106.01345.
- Turner, R. E. (2024). *An Introduction to Transformers*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023). Attention Is All You Need.

Cuantificación de Incertidumbre y Optimización

- Akiba, T. et al. (2019). Optuna: A next-generation hyperparameter optimization framework. *KDD*.
- Chen, N., Wiggins, S., & Andreou, M. (2025). Taming Uncertainty in a Complex World: The Rise of Uncertainty Quantification - A Tutorial for Beginners. *Notices of the American Mathematical Society*, 72(03), 1.
- Pei, J., Wang, C., & Szarvas, G. (2021). Transformer Uncertainty Estimation with Hierarchical Stochastic Attention.
- Snoek, J., Larochelle, H., & Adams, R. P. (2012). Practical Bayesian Optimization of Machine Learning Algorithms.